

Εργασία στο μάθημα

ΔΙΑΧΕΙΡΙΣΗ ΔΕΔΟΜΕΝΩΝ ΜΕΓΑΛΗΣ ΚΛΙΜΑΚΑΣ

Η εργασία έχει ως στόχο την ανάλυση μεγάλων δεδομένων και την παρουσίαση των αποτελεσμάτων σας. Η εργασία εκπονείται από ομάδες 3 φοιτητών/φοιτητριών και περιλαμβάνει 2 μέρη: το πρώτο μέρος είναι η συγγραφή μίας αναφοράς 6 σελίδων, ενώ το δεύτερο μέρος είναι η δημιουργία κώδικα για την εκτέλεση των πειραμάτων σας.

Μέρος 1^ο: Αναφορά

Η αναφορά θα πρέπει να ικανοποιεί τις εξής προδιαγραφές:

- (α) Να έχει μέγεθος έως 6 σελίδες A4, χρησιμοποιώντας γραμματοσειρά calibri μεγέθους 12pt και μονό διάστιχο.
- (β) Να περιλαμβάνει τις ακόλουθες ενότητες:
 - (β.1) Εισαγωγή.
 - (β.2) Ορισμός προβλήματος και κίνητρο. Προτείνεται να συμπεριλάβετε ένα παράδειγμα χρήσης των αποτελεσμάτων της, π.χ. σε ποιους είναι χρήσιμα;
 - (β.3) Σύντομη περιγραφή του συνόλου δεδομένων που χρησιμοποιήσατε.
 - (β.4) Περιγραφή της μεθόδου ανάλυσης των δεδομένων (να δώσετε ιδιαίτερη έμφαση σε αυτό).
 - (β.5) Πειραματικά αποτελέσματα και αποτίμησή τους (να δώσετε ιδιαίτερη έμφαση σε αυτό).
 - (β.6) Συμπεράσματα.
- (γ) Η υποενότητα της ανάλυσης των δεδομένων θα πρέπει να περιγράφει τις τεχνικές που χρησιμοποιήσατε. Έχει ιδιαίτερη σημασία να προσπαθήσετε να πείσετε τον αναγνώστη ότι η συγκεκριμένη τεχνική που χρησιμοποιήθηκε είναι αυτή που ταιριάζει στο πρόβλημα. Να είστε σαφείς

και περιεκτικοί.

(δ) Η ενότητα των πειραματικών αποτελεσμάτων θα πρέπει να περιλαμβάνει όλα τα πειράματα που χρησιμοποιήσατε. Συζητήστε τις παραμέτρους και ιδιαίτερα τους χρόνους εκτέλεσης, καθώς και μέτρα αξιολόγησης που χρησιμοποιήθηκαν. Συμπεριλάβετε κατά την κρίση σας πίνακες/σχήματα.

Μέρος 2^ο: Κώδικας

Τα πειράματά σας θα γίνουν στη γλώσσα Python. Μπορείτε να χρησιμοποιήσετε οποιαδήποτε πλατφόρμα υλοποίησης, π.χ. Jupyter-lab, Google Colab, IDLE κλπ. Το βασικό είναι να μπορούν να αναπαραχθούν τα αποτελέσματα. Δώστε μεγάλη προσοχή στη χρήση σχολίων στον κώδικά σας.

Σημείωση: Εάν χρησιμοποιήσετε εξωτερικές πηγές, θα πρέπει να τις αναφέρετε σε σχόλια μέσα στον κώδικα.

Πηγές συνόλων δεδομένων

Για την εκπόνηση της εργασίας μπορείτε να χρησιμοποιήσετε δεδομένα και από τις ακόλουθες ενδεικτικές πηγές:

- Google Data set search: <https://datasetsearch.research.google.com/>
- KDnuggets Datasets: <https://www.kdnuggets.com/datasets/index.html>
- kaggle Datasets: <https://www.kaggle.com/datasets>
- UCI Machine Learning Repository: <https://archive.ics.uci.edu/>

Η εργασία θα παραδοθεί έως τις **2/6/2025, 14:00** μέσω της πλατφόρμας ηλεκτρονικής μάθησης eclass.uniwa.gr. Παραδοτέα θα είναι συμπιεσμένο αρχείο **GROUP_NO.rar** με όνομα τον διψήφιο αριθμό της ομάδας σας (π.χ. **07.rar**), που θα περιλαμβάνει την αναφορά αποκλειστικά σε μορφότυπο pdf και τον κώδικα (είτε σε αρχείο .ipynb είτε σε αρχείο .py είτε και στα δύο, με επαρκή σχολιασμό).

Ο βαθμός της εργασίας θα συνεισφέρει κατά 45% στον τελικό βαθμό. Για να θεωρηθεί επιτυχημένη η εξέταση του μαθήματος, αρκεί ο συνολικός σταθμισμένος βαθμός να είναι μεγαλύτερος ή ίσος του 5.0.

Σημειώνεται ότι δεν θα υπάρξει παράταση.